

# HW2 Solution

## 18340013 陈琮昊

### 6.5

(a) 若  $N < D$ ,  $S_w$  不可逆。

(b) 因为  $S_B = \sum_{i=1}^C N_i (\mu_i - \mu)(\mu_i - \mu)^T$  (其中  $\mu_i$  为每类样本的均值,  $\mu$  为全部样本的均值,  $N_i$  为第  $i$  类样本所占个数)。由于  $S_B$  中的  $\text{rank}(\mu_i - \mu) = 1$ , 根据秩的性质:

$$\text{rank}(A) = \text{rank}(AA^T), \text{rank}(A + B) \leq \text{rank}(A) + \text{rank}(B)$$

可以知道  $\text{rank}(S_B) \leq C$ 。又因为存在线性组合使得  $\sum_{i=1}^C N_i (\mu_i - \mu) = 0$ , 因此根据上述性质可以得到  $\text{rank}(S_B) \leq C - 1$ 。则广义特征向量的个数最多为  $C - 1$ 。

(c) 因为当  $N > D$  ( $N \gg D$ ) 时,  $S_w$  通常是非奇异的, 故很大可能上为可逆矩阵。

(d)

第三步里, 不妨记对角化  $C$  得到的矩阵为  $D$ , 则  $D = Q^T C Q$  ( $C = Q^{-T} D Q^{-1}$ ) 为对角矩阵。

$X^T S_B X = Q^T G^{-1} S_B G^{-T} Q = Q^T C Q = D$ , 因为  $D$  为对角矩阵, 故  $X^T S_B X$  为对角矩阵。

$X^T S_W X = Q^T G^{-1} G G^T G^{-T} Q = Q^T Q = I$  ( $Q$  正交)。故  $X^T S_W X$  为单位阵。

由于  $X^T S_B X (= D)$  为对角矩阵, 由对角矩阵性质可知该矩阵的特征值即为对角线上元素。

因此若证明广义特征值  $\lambda$  位于  $X^T S_B X (= D)$  的对角线上, 只需证  $Dt = \lambda t$ 。

(其中  $t$  为  $D$  的特征向量, 该特征向量与本题的广义特征向量  $w$  不同)

将  $C = G^{-1} S_B G^{-T}$ ,  $S_W = G G^T$  代入  $S_B w = \lambda S_W w$  得:

$$G C G^T w = \lambda G G^T w, \text{ 两边同时左乘 } G^{-1}: C G^T w = \lambda G^T w$$

将  $D = Q^T C Q$  ( $C = Q^{-T} D Q^{-1}$ ) 代入得:  $Q^{-T} D Q^{-1} G^T w = \lambda G^T w$

又因为  $Q^T Q = I$  ( $Q$  正交), 故上式化简得:  $D(Q^{-1} G^T w) = \lambda(Q^{-1} G^T w)$

可以看到取  $t = Q^{-1} G^T w$  即可满足  $Dt = \lambda t$  形式, 故证明了广义特征值  $\lambda$  位于  $X^T S_B X$  的对角线上。

根据前面的推导可以知道:  $D(Q^{-1} G^T w) = \lambda(Q^{-1} G^T w)$ , (即  $Dt = \lambda t$ )

由于  $D$  为对角矩阵 (必对称), 那么必存在标准正交的特征向量系满足:

$$t_i^T t_j = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases}$$

回推可得  $t_i^T t_j = (Q^{-1} G^T w_i)^T (Q^{-1} G^T w_j) = w_i^T S_W w_j$  (根据  $S_W = G G^T$ ,  $Q Q^T = I$ )

$$\text{即有: } w_i^T S_W w_j = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases}$$

所以在矩阵  $S_W$  下, 广义特征向量  $w$  之间两两正交且具有单位范数。

最后再证明广义特征向量位于  $X$  的每一列上:

设广义特征向量组为  $\{w_1, w_2, \dots, w_n\}$ 。其中  $w_i$  为列向量, 对应的特征值为  $\lambda_i$ 。

显然有  $S_B w_i = \lambda S_W w_i$ 。若  $X$  的每一列为特征向量, 不妨记  $X = [w_1, w_2, \dots, w_n]$ 。

$$\text{而 } w_i^T S_B w_j = \lambda w_i^T S_W w_j \begin{cases} 0 & i \neq j \\ \lambda_i & i = j \end{cases}$$

有  $X^T S_B X = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) = D$  符合前面所证。

即便  $X$  的列与列之间发生了顺序上的交换, 得到的  $D$  也是对角阵, 同样对角线上为广义特征值。

故广义特征向量位于  $X$  的每一列上。

## 7.4

(a)

$$\begin{aligned} \min \quad & \frac{1}{2} w^T w \\ \text{s.t.} \quad & y_i w^T x_i - 1 \geq 0 \end{aligned}$$

(b)

首先得到拉格朗日函数： $L(w, \alpha) = \frac{1}{2} w^T w - \sum_{i=1}^n \alpha_i (y_i w^T x_i - 1)$

$$\text{s.t.} \quad \alpha_i \geq 0, 1 \leq i \leq n.$$

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^n \alpha_i y_i x_i = 0, \text{ 可得 } w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\text{故而 } \frac{1}{2} w^T w = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$\text{将 } w = \sum_{i=1}^n \alpha_i y_i x_i \text{ 代入得 } L(w, \alpha) = -\frac{1}{2} w^T w + \sum_{i=1}^n \alpha_i$$

求  $\min_w L(w, \alpha)$  对  $\alpha$  的极大，即得到对偶问题：

$$\max_{\alpha} \quad -\frac{1}{2} w^T w + \sum_{i=1}^n \alpha_i = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j + \sum_{i=1}^n \alpha_i$$

$$\text{s.t.} \quad 0 \leq \alpha_i \leq C, i = 1, 2, 3, \dots, n.$$

加负号将求解极大转为求解极小，便得到了题目要求的对偶形式：

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i=1}^n \alpha_i$$

$$\text{s.t.} \quad 0 \leq \alpha_i \leq C, i = 1, 2, 3, \dots, n.$$

如果得到关于  $\alpha$  的解为  $\alpha^*$ ，可以通过  $w = \sum_{i=1}^n \alpha_i^* y_i x_i$  来得到最优的  $w^*$ 。

(c)

偏置项  $b$  对应  $d+1$  维数据的情况下， $w$  的  $d+1$  维。

因为  $w_d^* = \sum_{i=1}^n \alpha_i^* y_i x_i$ ，且在第  $i+1$  维的情况下  $x_i = 1$ ，

$$\text{所以 } b = w_{d+1}^* = \sum_{i=1}^n \alpha_i^* y_i$$

## 8.6

根据式 (8.38), 可知  $y^* = \underset{1 \leq i \leq m}{\operatorname{argmax}} p(y = i|x; \theta)$

$$\text{而 } p(y = i|x; \theta) = \frac{p(x|y=i; \theta)p(y=i)}{p(x; \theta)}$$

因为  $p(x; \theta)$  与  $y$  无关, 而题目里又给定  $p(x|y = i; \theta)$  满足高斯分布,  $p(y = 1) = p(y = 2) = 0.5$

所以优化问题转化为:  $y^* = \underset{1 \leq i \leq m}{\operatorname{argmax}} p(x|y = i; \theta)$

$$\text{故原题等价于 } y^* = \begin{cases} 1 & p(x|y = 1; \theta) > p(x|y = 2; \theta) \\ 2 & p(x|y = 1; \theta) \leq p(x|y = 2; \theta) \end{cases}$$

$p(x|y = i; \theta) = N(\mu, \Sigma)$ , 记  $D$  为  $x$  的维度, 则  $PDF$  为:

$$p(x|y = i) = \frac{1}{(2\pi)^{\frac{D}{2}} (\Sigma)^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu_i)^T \Sigma^{-1} (x-\mu_i)}$$

因为  $\Sigma$  相同, 所以只需比较  $-(x - \mu_1)^T \Sigma^{-1} (x - \mu_1)$  与  $-(x - \mu_2)^T \Sigma^{-1} (x - \mu_2)$  的大小关系:

$$\begin{aligned} & -(x - \mu_1)^T \Sigma^{-1} (x - \mu_1) - [-(x - \mu_2)^T \Sigma^{-1} (x - \mu_2)] \\ &= (\mu_1^T - \mu_2^T) \Sigma^{-1} x + x^T \Sigma^{-1} (\mu_1 - \mu_2) + (\mu_2^T \Sigma^{-1} \mu_2 - \mu_1^T \Sigma^{-1} \mu_1) \end{aligned}$$

$$\text{因为 } x^T \Sigma^{-1} (\mu_1 - \mu_2) = (\mu_1^T - \mu_2^T) (\Sigma^{-1})^T x$$

$$\text{故代入上式得: } -(x - \mu_1)^T \Sigma^{-1} (x - \mu_1) - [-(x - \mu_2)^T \Sigma^{-1} (x - \mu_2)]$$

$$= (\mu_1^T - \mu_2^T) (\Sigma^{-1} + (\Sigma^{-1})^T) x + (\mu_2^T \Sigma^{-1} \mu_2 - \mu_1^T \Sigma^{-1} \mu_1)$$

$$\text{令 } w^T = (\mu_1^T - \mu_2^T) (\Sigma^{-1} + (\Sigma^{-1})^T), b = \mu_2^T \Sigma^{-1} \mu_2 - \mu_1^T \Sigma^{-1} \mu_1$$

故当  $w^T x + b > 0$  时,  $-(x - \mu_1)^T \Sigma^{-1} (x - \mu_1) > -(x - \mu_2)^T \Sigma^{-1} (x - \mu_2)$ , 即  $p(x|y = 1; \theta) > p(x|y = 2; \theta)$ ;

故当  $w^T x + b \leq 0$  时,  $-(x - \mu_1)^T \Sigma^{-1} (x - \mu_1) \leq -(x - \mu_2)^T \Sigma^{-1} (x - \mu_2)$ , 即  $p(x|y = 1; \theta) \leq p(x|y = 2; \theta)$ .

$$\text{即原题可以表示成如下形式: } y^* = \begin{cases} 1 & w^T x + b > 0 \\ 2 & w^T x + b \leq 0 \end{cases}$$

$$\text{其中 } w = [(\mu_1^T - \mu_2^T) (\Sigma^{-1} + (\Sigma^{-1})^T)]^T = (\Sigma^{-1} + (\Sigma^{-1})^T) (\mu_1 - \mu_2), b = \mu_2^T \Sigma^{-1} \mu_2 - \mu_1^T \Sigma^{-1} \mu_1$$

## 9.1

$$\begin{aligned} \|y_1 - y_2\|_2^2 &= (E_d^T(x_1 - \bar{x}) - E_d^T(x_2 - \bar{x}))^2 = (E_d^T(x_1 - x_2))^2 = (E_d^T(x_1 - x_2))^T E_d^T(x_1 - x_2) \\ &= (x_1 - x_2)^T E_d E_d^T (x_1 - x_2) \end{aligned}$$

而由 (9.15) 式可知  $d_A(x, y) = (x - y)^T A (x - y)$

$$\text{即 } d_A(x_1, x_2) = (x_1 - x_2)^T A (x_1 - x_2).$$

通过对比可以知道当  $A = E_d E_d^T$  时,

$$\text{有 } d_A(x_1, x_2) = \|y_1 - y_2\|_2^2 \text{ 成立, 得证.}$$

## 10.3

首先有该式成立:  $CE(p, q) = h(p) + KL(p||q)$

而  $KL(p||q) \geq 0$ , 故  $CE(p, q) \geq h(p)$  成立

等号成立时当且仅当  $KL(p||q) = 0$ ,

即对于任意的  $x$ , 有  $p(x) = q(x)$ .